

Agentic AI Coding × Rust

計算物理コードを検証可能に育てる

品岡 寛

埼玉大学

事前準備

事前準備 (各自, 当日までに)

1. CLI 型エージェントを 1 つ導入 してくる.
 - 無料: [Gemini CLI](#) / ChatGPT Plus 以上: [Codex](#) / その他はご自由に.
 - 導入手順: [Satoshi Terasaki](#) / [Junya Ito](#).
2. プログラミング言語の開発環境を用意する.
 - 今回は [Rust](#) を使うが何でもよい. Rust なら [Cargo](#) を [install](#) (参考).

今日の流れ


- 前半 = 方法論 / 後半 = 2D Ising ハンズオン.
- 当日は **環境チェックのみ**: 方法論と実習に時間を使う.
- **2D Ising は よく知られている** ので, 無料モデルでも完走できる (多分).

導入




自己紹介と今日の立ち位置

- 東大 PhD → スイス Postdoc → 埼玉大 PI (2015～)
- 量子多体計算 ～ 第一原理計算まで幅広い経験
- IR basis / sparse modeling / tensor networks
- **C++ / Python / Julia / Fortran** の本格的な実経験
- OSS と Community へ貢献



今は 1 行も書かないし, 逐行も読まない. それでも **手動コーディング**より **agentic coding** の方が**信頼できる** と感じる. なぜか?

コーディングの産業革命: 手工業から工業へ



人間が1点ずつ丁寧に
= 手作業コーディング


金型で大量生産 (高速・均質)
= 理想的な agentic coding

同じ転換が, いま agentic coding で起きている.

理想的な agentic coding をどう実現するか考える段階.


手作業 (職人モデル) の限界

Scientific computing



Held up by a few artisans
(PD / staff leave → unmaintainable)

Large project



Issues & PRs keep piling up
(manual review can't keep up)

→ いずれも **人手で支えるモデル** が抱える限界。

よく言われる批判: “AI slop”

巷では agentic coding の成果物を “AI slop” と呼ぶ声がある:

職人性の喪失

Sinclair Target

*“...would prefer not to use agentic tools **even if they worked as advertised.**”*

宣伝通り動いても, 仕事への care を失う. [Quality in the Age of Slop, 2026](#)

保守の崩壊

D. Stenberg (curl)

“The current torrent of submissions put a high load on the curl security team...”

AI slop に埋もれ curl は bug bounty を終了 (2026). [The Register](#)

共有資源の劣化

Baltes et al.

*“...a tragedy of the commons, where individual productivity gains **externalize costs onto reviewers, maintainers, and the broader community.**”*

[“An Endless Stream of AI Slop”, arXiv:2603.27249](#)

過大広告への反動

Anthropic C compiler

16 並列 Claude で C コンパイラ (100K 行, \$20k) を構築. 別 benchmark では **GCC -O0 より速いが GCC -O2 には届かない**. こうした showcase は評価軸がずれると **AI 反対派を増やす**.

[Anthropic · benchmark](#)

私の解答

いずれも agentic coding の本質的な限界ではなく、AI を前提に体制を組み替えれば
解消する 移行期の課題である。

職人性の喪失

Sinclair Target

伝統工芸と同じく、手動コーディングが残り、意味を持つのは **ごく限られた領域** に過ぎない。

保守の崩壊・共有資源の劣化

D. Stenberg, Baltes et al.

手動の PR・マージを前提とした運用を **維持する必要はない**。AI を前提としたメンテナンス体制へ移行すべきであり、**人間の関与はむしろボトルネック** である。

過大広告への反動

Anthropic C compiler

最適化不足は **AI 不能の証拠ではない**。性能 oracle と緊密な human-AI loop の不足として読むのが妥当である (後述)。

今日の主張 (概要)

信頼の置き場所を 目視 から 機械的・外部検証 へ移した:

Compiler ・ test ・ oracle ・ rules が, 目視に代わって正しさを支える.

AI の高速生成は工業的な大量生産である. 製品を 1 個ずつ直すのではなく, 金型 (= 正本: rules ・ oracle) を直す.

コーディングエージェントの基礎

Chat 型 vs CLI 型エージェント

Chat 型 (ブラウザ対話)	CLI 型 (ターミナル)
質問して答えをコピペ	ファイルを直接編集・実行
ローカル環境に触れない	リポジトリ・git を操作
1 往復ずつ人が運ぶ	マルチステップを自律実行

CLI 型は **長時間の自律実行を狙う設計**。今日の主役はこちら。

近年は両者の境界が薄れ、**エージェント型が両形態を飲み込みつつある**。GUI から自律実行を呼ぶ Codex App はその典型である。

世代で言えば Gen1 (Cursor / Copilot) → Gen2 (Claude Code / Codex / ...)。MIT missing-semester: [agentic coding](#)

代表的な CLI エージェント (ハーネス)

- Claude Code Anthropic. ターミナル/IDE で自律コーディング
- Codex CLI OpenAI. Rust 製 OSS, ChatGPT プランに同梱
- Gemini CLI Google. OSS, 無料枠あり
- Kimi CLI Moonshot (中国系). モデル K2.7 Code
- OpenCode OSS, プロバイダ非依存
- Pi 最小構成の OSS. 拡張・skill を自分で足して育てる (最小主義者向け)

ハーネス ≠ モデル

- ハーネス = CLI ツール (ファイル編集・コマンド実行・ツール呼び出しの枠組み).
- モデル = 裏で動く LLM. 多くのハーネスは モデルを差し替え可能.
 - ▶ 中立: OpenCode / Gemini CLI ・ 自社統合寄り: Claude Code / Codex.
- 性能は モデル, 操作性・自律度は ハーネス で決まる. 両方を選ぶ.

サブスク vs API, 廉価モデル

サブスク	Claude Pro \$20/月 (Claude Code 込) / ChatGPT + Codex. 月額固定 + 利用枠
API 従量	使ったトークン分課金. ハーネスに任意モデルを接続

廉価なコーディング向け API (2026): DeepSeek V4 Flash (入力 \$0.14 / 出力 \$0.28 per 1M) ・ Kimi K2.7 Code. 例: OpenCode + 廉価 API で低コストに始められる.

料金・モデル名は 2026 年 6 月時点. 世代更新が速い.

スキルとは

- **Skill** = エージェントの **手順書** (markdown). 抽象的な作業を明示的な小ステップに分解する.
- プログラムの関数に近いが, 操作対象は **データでなくエージェントの振る舞い**.
- 関連する作業で **自動的に発火** し, skill が skill を呼んで複雑な手順を構成する.
- **CLAUDE.md** / **AGENTS.md** = セッションを越える記憶 (規範・コマンド・構成).
 - リポジトリ内に置く **プロジェクト固有** の情報であり, git でチームや将来の自分と共有する (ユーザ全体の設定とは別).

実際のワークフローはこんな感じ

superpowers の Skill が **brainstorm** → **plan** → **execute** を強制する (各段階は自動発火):



- 出発点は prompt でなく **数式つき設計書**. 検証 (oracle / test) も同時に設計する.
- 実装後は **コード** ↔ **アルゴリズム・数式** の対応を AI に出させて照合 (コードそのものは読まないこともある).
- Execute は TDD + サブエージェント分割, Review で問題が出れば前段階へ戻る.

この1年: agentic coding の限
界を試す

これまでの経緯

2025 年 10 月以降, 私はコードを一行も書いていない. 生成コードも逐行では読まない.

2025 年 1 月 Cursor を開始, 依然としてソースコードを見る世代

2025 年 10 月 `SparseIR.jl` を Julia → Rust へ移植開始

2025 年 12 月 Claude Code へ移行: 生成コードを逐行で読むのをやめた

2026 年 1 月 tensor4all-rs 開発開始: Julia TN eco の Rust port

2026 年 2 月 tenferro-rs 開発開始: Rust 製の PyTorch 的 tensor stack

2026 年 3 月～ Codex, Claude, DeepSeek, Kimi などを使い分け開発を進める

作ったもの: tensor4all-rs

Julia の tensor learning stack を Rust に移植.

[TensorCrossInterpolation.jl](#) / [QuanticsTCI.jl](#) など / [SciPost Phys. 18, 104 \(2025\)](#) / [tensor4all](#)

GitHub: github.com/tensor4all/tensor4all-rs

- Julia による大規模開発の辛さ: (pre)compile の遅さ, 実行時に出る型不安定性等
- 2026 年 1 月 1 日開始 (元々は agentic coding の「限界」を試す冬休みの自由研究)
- 人間数名 + AI (Claude Code から Codex メインへ)
- 2 ヶ月で 353 commits ・ 最初の 2 週間で +61,486 行 (151 files)

→ 共同研究者間の議論 (AI slop, 教育法, Julia は不要か?) は, まだ続いている.

“多数の試行錯誤と失敗から, 正しい agentic coding 法が見え始めたところ”

設計, テスト・検証, 適した言語, (教育法)...

Agentic coding を限界まで押してみた

最初は「モノシリック構造」から始めた:

- ITensors.jl の必要部分 (Index system, tensor contraction)
- QTT/TCI

の移植


(予想通り) 多数の問題が発生

- 抽象化を壊す: 低階層の機能を高階層で import して使ってしまう (その場のしのぎ)
- ユニットテストのしきい値を勝手に緩める (バグを直すのを諦める)
- BLAS を使わずに nested loops を書く (結果は正しいが...)
- 1つのソースファイルの行数が数千行超え
- ...

複雑さが増え続ける

- 個別修正では追いつかない.
- 長期保守には、思想とデザインルールを **統一的に育てる** しかない.
- **さもないと複雑さが増え続ける.**

Fix each product vs. fix the mold



修正するのは「コード」ではなく「ルール」であるべき.

参考

- Heinrich pyramid: 1 件の重大事故の背後に多数の軽微事故・near miss がある, という安全工学の経験則.
- 航空事故調査: ICAO Annex 13 は, 調査目的を blame ではなく再発防止と定める.

[SKYbrary: Heinrich Pyramid](#) · [ICAO Annex 13](#) · [NASA ASRS](#)

Agentic coding における(私の)対処法

- 「ルール」や「制度」を作ること, AI の行動を矯正
- 機械的に監査し, コードを一括修正する仕組みを構築

(このような仕組みは手動コーディングでも元々重要)

→ AI の圧倒的に高速なコード生成と品質管理を両立

モノリシック → 分離構造 (構造による強制)

巨大な tensor4all-rs を，役割の異なる独立した層に分割する．

Tensor4all.jl

github.com/tensor4all/Tensor4all.jl

人間向けインターフェース (Julia, ITensors 互換)

tensor4all-rs

github.com/tensor4all/tensor4all-rs

テンソルネットワーク: TreeTN / QTT / TCI

tenferro-rs

github.com/tensor4all/tenferro-rs

汎用テンソル計算 + 自動微分 + GPU (PyTorch/JAX 的)

tidu-rs


github.com/tensor4all/tidu-rs

汎用自動微分エンジン

一旦分割すれば，AI は各層の中でしか動けず，階層構造を壊せない．

AI とともに PyTorch / JAX を分析して設計． (*Jin-Guo Liu: tenferro* 初期設計, *Satoshi Terasaki: 開発支援*, *tensor4all collaboration: tensor4all-rs / Tensor4all.jl* 開発)

各階層のモジュール化




einsum, linalg, and FFT are not built-ins — they register through the same public ExtensionOp interface available to any crate.

Rust はモジュール/クレート階層に沿って 公開/非公開 を制御可能

レファクタリングを繰り返す

Code frequency over the history of **tensor4all/tenferro-rs**



大規模なリファクタリングを繰り返して品質を上げる

可読性より，検証可能性

以下の議論は「巨大なコード」の開発を前提とする．

言語選択の理由が逆転: 私の発言の変遷

2023 年 3 月 (那覇, 計算物理春の学校 2023 前夜祭)

最近では Jupyter Notebook でプロトタイプを作ることが多く、数式とコードが似ていてレビューしやすく、メモリ管理に気を使わなくて良い Julia が楽。Rust にも興味はあるが、一般の学生が覚えるには敷居が高く、数値計算ライブラリもまだ揃っていない。

2026 年

最近ではプロトタイピングに Jupyter Notebook は使わない。メモリ管理が厳格で明示的な Rust の方が agentic coding には効率的である。エージェントがコードを書くので、学習曲線の急峻さも問題ない。数式との整合も AI の助けがあればコードが少々長くても問題ない。足りない数値ライブラリは Rust に移植できる。

可読性よりは検証性

手動コーディング時代: 各言語の“嬉しさ”

Fortran	配列が言語ネイティブ・手書きループでも速い・LAPACK / BLAS が目の前
Python	対話的に試せる (REPL / notebook)・numpy / scipy / matplotlib・可視化が即座
Julia	数式に近い記法 (broadcast / Unicode)・JIT で速い・prototype が production に近い

共通点: すべて 人間が手で書いて・読んで・保守する コストを下げる工夫.

言語を選ぶ基準が変わる: 大規模開発

これまで重要だった指標は、すべて **人間が書いて保守する** 前提:

従来の指標	Agentic 時代
可読性: 一行ずつ追える	検証可能性 : oracle で検査
学習曲線の緩やかさ	急峻さは AI が肩代わり
数式への近さ: 目で確認	機械チェックを併用
書く速度	もはや bottleneck ではない

読みやすさ より **検査しやすさ**.

Readable source $\neq$ Inspectable implementation

読みやすい ことと 検査しやすい ことは別物.

例: 数式に近く 見える Julia の broadcast 代入も, 挙動は見た目で確定しない:

```
b = a          # b と a は同じ配列を指す (別名)  
a .+= c        # in-place 更新なら b も変わる ← 副作用
```

Aliasing / mutation / allocation は行単位の見ただけからは見えない.

ではどの言語が検証可能性に向くのか.

Rust とは (この聴衆向けに最小限)

C++ 並の
高速性

+

Julia のような
ビルド/依存管理

+

メモリ管理
の厳密さ

- **Mozilla** 発のシステム言語. ブラウザエンジン (Servo) のために開発され, 2015 に安定版 (1.0).
- 信頼性が評価され **Linux カーネル** に正式採用 (v6.1~, C に次ぐ第 2 言語).
- **所有権 (ownership)**: GC 無しでメモリ安全. データ競合・dangling を **コンパイル時に** 排除.
- **Cargo**: ビルド・依存解決・テスト・ベンチが標準で一体.
- C++/Fortran/Python/Julia から呼び出し可能

Aliasing と Rust: 借用の規則

同時に持てるのは **&T を複数** (共有・読取) **または** **&mut T を 1 個だけ** (排他・書込). 両立しない.

✓ 不変借用は複数 OK



&v は同時に何個でも持てる (読取専用)

✓ 可変借用は 1 個だけ



&mut v は同時に 1 個 (排他・書込可)

× 可変 + 不変 の同時



書込み中に別名から読める → 禁止

× 可変借用が 2 個



二重の書込み権 → 禁止


→ aliasing と書込みの両立を **コンパイル時** に排除. データ競合・dangling が原理的に起きない.

エコシステムの急成長


crates.io crate count by year

Source: crates.io DB dump, 2026-06-02T02:00:24.375042Z. Includes deleted crates when reconstructing Jan 1 active counts.
2026 is partial through the dump timestamp.

Active crates at Jan 1



New crates created in each year



Counting rule: crates.created_at plus deleted_crates.created_at; active_at_jan1 subtracts crates deleted before that date.

2026 年には NVIDIA も Rust 製 CUDA カーネルコンパイラ [cuda-oxide](#) を公開 (実験段階).

代表的なパッケージ (科学計算)

<code>ndarray</code> / <code>ndarray-linalg</code>	NumPy 的な多次元配列 + BLAS/LAPACK
<code>nalgebra</code> / <code>faer</code>	線形代数 (<code>faer</code> は高速)
<code>rayon</code>	スレッド並列 (共有メモリ, 1 行で並列化)
<code>mpi</code> (<code>rsmapi</code>)	分散並列 (プロセス間・ノード間)
<code>num-complex</code>	複素数
<code>Burn</code>	Rust 製 深層学習/テンソル (<code>autodiff</code> ・GPU)
<code>hdf5-metno</code>	HDF5 入出力

線形演算の自動微分をサポートするライブラリがなかったので, `tenferro` の開発を始めた.

Why Rust? AI との fast feedback loop

Python / Julia は **速く書く** ために設計された. AI 時代にこの利点は **反転** する:

Python / Julia	Rust + AI
手で書くのが速い	AI が書く: 速度は同じ
エラーは実行時に判明	コンパイル時に捕捉
検証には実行が必要	cargo check 数秒
AI のミス発見が遅い	AI のミスを 即座に 発見

*巨大なコードが前提である.

Zenn: Why I Migrated from C++ to Rust

個人的な体験: tenferro-rs の開発体験

- AI が ownership / lifetime の **機械的複雑さ** を肩代わり.
 - 人間は **アルゴリズム・設計・正しさ** の検証に集中できる.
- **逐行レビューはしない**. それでも正しさの確信は手作業時代より高い.

→ Julia/C++/Python で感じていた「大規模化すると検証が難しくなる」という不安が **なくなった**.

[tensor4all-meta/docs/why_rusty_julia.md](https://github.com/tensor4all-meta/docs/blob/main/why_rusty_julia.md)

選ぶ基準は 認知コスト最小化 から 検証可能性最大化 へ

3 本柱で支える

巨大・高機能なコードを 3 本柱で支える

tenferro-rs は 約 13 万行, einsum ・ FFT ・ 自動微分 (AD) ・ GPU まで担う高機能スタック. v0.1 を公開 (フル機能は実装済み, ただし API 未確定の初期版). 逐行レビューは不可能で, AI の設計選択も毎回ぶれる.

人間が見張る代わりに, 3 本柱で支える.

tenferro-rs (約 13 万行)

einsum ・ FFT ・ 自動微分 (AD) ・ GPU ...

柱 1

Unit / Integration
test

並列コンパイル + 並列テスト
高速な fast feedback

柱 2

Oracle / Benchmark

正しさ・性能の外部基準
AI が勝手に変えられない

柱 3

正本 (Rules / Docs)

AI と人間が従う
source of truth

[tensor4all.org/blog: Introducing tenferro-rs \(v0.1, 2026\)](https://tensor4all.org/blog: Introducing tenferro-rs (v0.1, 2026))

柱 1: Unit / Integration test

入出力を期待値と突き合わせる自動テスト群. 粒度で2階層に分ける:

Unit test 関数・モジュール単体を細かく検証 (Rust では同ファイル内の
#[test])

Integration test 複数モジュール・crate を結合した挙動を検証 (Rust では tests/
配下)

- コードを変えるたびに全テストを回し, 壊れた箇所を即座に検出する.
- **Rust が効く点**: 依存 crate を **並列コンパイル**, テストも **デフォルトで並列実行**.
 - ▶ 実例 (tenferro-rs, Macbook Pro): **フルスクラッチビルド 2分** ・ cargo check 瞬時 ・ AI edit→該当 test 数十秒.
 - ▶ AI が実装を書き換えても, 緑/赤が即座に返る fast feedback loop.


柱 2: Oracle と Benchmark (外部基準)

- **oracle** = 正しさの外部基準: 解析解・reference 実装・不変量 (invariants).
- **benchmark** = 性能の外部基準: 再現可能に測る.
- **別リポジトリ (外部) に置く** → AI が勝手に変えられない.


例: **tenferro-benchmark** (性能) / **tensor-ad-oracles** (AD の数値的正しさ).

柱 3: 正本 (source of truth) はなぜ要るか

- **正本** = rules ・ design ・ worklog の総体. AI と人間が共に従う source of truth.
- 育たないと **AI slop**: 失敗が個別修正に留まり, 同型の問題が別の場所で再発する.
- **モグラ叩き** (個別修正) では追いつかず, 複雑さが増え続ける.
- 正本は 3 本柱で **最も過小評価されやすい**. 次スライドから **育て方** を扱う.



AI は長期記憶を持たない




プロジェクトの判断は AI の会話履歴や memory ではなく, repo 内の正本に残す. 漫画: [Jin-Guo Liu: Sustainable Automation](#)

正本は失敗から育てる

2025 年 10 月以降, 逐一の介入をやめ, 判断を **正本** として蓄積する方へ移した. **失敗**を一般化して育てる.

実装 → 失敗 → 一般化 → rule/oracle → 次の制約.



tenferro-rs / REPOSITORY_RULES.md (抜粋)

- ... are first-class crates, not a broad “tenferro” facade.
- No naive CPU loop fallbacks. Use strided-kernel / faer / BLAS.

これは私が経験した **失敗から生まれたルール** (内蔵→分離, naive loop の痛み).

正本を溜めて, 保つ

AGENTS.md	AI と人間が従う作業規範
REPOSITORY_RULES.md	禁止事項 ・ source of truth ・ 性能契約
docs/design/, worklogs/	守る設計思想 ・ なぜその判断をしたか
oracle / benchmark	正しさ ・ 性能の外部基準

- 正本↔コードの整合性検査は エージェント自身に継続的に やらせる (drift = correctness concern).
 - 信頼の対象を「AI の説明」から rule / oracle / CI / provenance へ移す.
- では, 育てた正本が本当に効いているかを 外から確かめる.

外から確かめる: 第三者 AI に監査させる

Ask AI: 次の3つの repo を読み, 巨大コードベースの一貫性・品質管理の工夫を調べて.

- ・ <https://github.com/tensor4all/tenferro-rs>
- ・ <https://github.com/tensor4all/tenferro-benchmark>
- ・ <https://github.com/tensor4all/tensor-ad-oracles>

私の試行では, ChatGPT Pro は repo を読むだけで品質管理を再構成した:

- **性能** = tenferro-benchmark / **AD の正しさ** = tensor-ad-oracles → **柱2 (外部基準)** を抽出した.
- **構造の一貫性** = CI + repository rules + first-class crate 分割 → **柱3 (正本)** を抽出した.

正本が揃っていれば, 第三者 AI でも設計意図を読み取れる.

再現用 prompt は上の code block. 対象 repo は public GitHub repo として外部から読める.

監査を自動化する: 検知は Bot, 修正は人間

正本 + コード



監査 Bot を private CI で継続実行 (人間も同ツール可)



不整合・バグを Issue に自動起票



人間 が GPT-5.5 で 一括修正

自動修正に任せきらないのは 信頼性ではなく 責任と選択の問題: 多数のバグの背後に設計の不具合があることもある.

教育とコミュニティ

共同研究者からの懸念

新しい workflow には反論もある (tensor4all 共同研究者):


① library $\neq$ application	application は reference answer が無い
② 学習段階への配慮	junior に senior の workflow をそのまま求めるのは早い
③ Julia の読みやすさ	小さな notebook は 数式との整合性を目で確認しやすい

個人的な回答

①	application でも 対称性・極限・保存則 などチェックできる対象はある。それを探することが重要。
②	学習段階で分ける: 基礎は手書きで学び, 研究レベルで agentic engineering を学ぶ。一律に求めない。
③	目視チェックが信頼できるとは限らない。AI に擬似コードを生成させて照合を併用すれば, Rust / C++ でも分かりやすい。

もう既に「産業革命」は起きている。実践から教育のパイプラインを構築する必要がある。過去のスタイルにこだわる必要はない。

学習曲線: 急な序盤を AI が肩代わりする



Rust の美味しいところだけが残る.

研究室の学生も Julia から Rust へ移行中.

Workflow in agentic coding era: 言語は混在してよい

- 以前: Jupyter Notebook で対話的にプロトタイピングした.
- 今: AI に自然言語で指令
コード生成 → 計算 → 結果をファイルに保存 → プロット
- Prototyping のために Jupyter Notebook は 必須ではない.
- 全計算を単一の言語でやる必要はない. 既存資産を活かしつつ, 段階的に Rust へ移行 できる.

教育パイプラインを作る: Rust 計算物理チュートリアル

研究室 (埼玉大) で Rust 計算物理学チュートリアル を作成中. saitama-cond-mat.github.io/rust-computational-physics-tutorial

- 対象: 物理の基礎がある 学部上級～大学院初級 (プログラミングは初級でよい).
 - 内容: 基礎・開発環境 → 数値解法 (微分方程式・線形代数・Fourier・Monte Carlo) → 物理シミュレーション (力学・流体・統計力学・量子) → 並列化・最適化.
 - 方針: ルーチンな実装は AI に任せ, 物理的・数値的な正しさは人間が検証する.
- 本日の方法論を, 計算物理の教材 として実装しようとしている (貢献歓迎!).

論点: AI 時代の OSS 共同開発はどうなるか

① Issue と PR (どちらも pile up していた)

- Issue の価値は上がる: バグ報告・新機能要望 = 意図と仕様. AI には生み出せない部分.
- PR の役割は縮む: 小規模修正には有効. 大規模な最適化は Issue を起点に主開発者 + AI が一貫実装 する方が速く, 整合的.
 - ▶ 前向きに言えば, 良い Issue を集める ことが共同開発の中心になる.

② コードの共用 (AI でコピー・移植が容易に)

- 基礎ライブラリの乱立は避けた: 信頼性と検証コストの問題. 少数を皆で育て, oracle / test で支える.
- 応用に近い層は共用の必要が薄れる: 各自がコピーして改変すればよい.

→ PR も応用コードも共有価値が下がるなら, コミュニティは何を共有するのか.

まとめ



まとめ

1. **ワークフロー**: brainstorm → plan → execute. prompt でなく **数式つき設計書** から始め, 検証を先に設計する.
2. **3本柱で支える**: unit / integration test ・ oracle / benchmark ・ 正本 (rules) で巨大コードを維持する.
3. **教育**: 基礎は手書き, 研究レベルで agentic engineering. 学習段階で分ける.

→ 人間の仕事は **プロジェクトの提案・設計・検証** が主になる.

ハンズオン: 2D Ising で検証駆動 開発

セットアップ: 最初に AI に指示すること

- 最初に **Superpowers** を導入: AI に URL を渡して「インストールして」と頼むだけ (github.com/obra/Superpowers). brainstorm → plan → execute を強制する skill 群.
- **git** は必須: 履歴・差分・レビュー・CI の前提. `git init + .gitignore` から始める.
- 言語は今日は **Rust**. Python / Julia でもよい (oracle が組めれば言語は本質でない).
- Rust なら **標準ディレクトリ構成 + テスト階層** を作らせる:
 - `src/` 内の `#[cfg(test)]` に **unit test** ・ `tests/` に **integration test**.
- 併せて最初から: `AGENTS.md` / `CLAUDE.md` (規範・コマンド・構成) ・ `README` ・ `cargo fmt + clippy` ・ **seeded RNG (再現性)** ・ 結果はファイル保存しプロットは分離.

今日のサイクルと 2 つのタスク

前半の **superpowers ワークフロー** を 2D Ising に適用する. 各タスクで回す **1 周のサイクル**:

- Step 1 AI に下調べさせ, 数式つき設計書 (markdown/LaTeX) にまとめさせる
- Step 2 何を unit test するか議論し, oracle と検証計画を決める
- Step 3 実装 → 数式・擬似コード・invariant を出させて照合
- Step 4 oracle で検証 (Onsager と比較, $\langle M \rangle$ の有限時間挙動)
- Step 5 得た知見を正本 (rules) に書き残す

- **Task 1**: 基本の 2D Ising (Metropolis).
- **Task 2**: アルゴリズム拡張 (レプリカ交換) = 別タスク. また **Step 1 から** 同じサイクルを 1 周.

題材と仕様: 2D Ising

- 統計力学の定番: 厳密解 (Onsager) があり **oracle が揃う**. well-known で無料モデルでも実装できる.
- $H = -J \sum_{\langle ij \rangle} s_i s_j$ (周期境界), Metropolis 更新. 観測量 = energy / magnetization / 比熱 / 帯磁率.

既存教材 [rust-computational-physics-tutorial](#) の Ising 章が下敷き. 厳密解は Onsager (1944).

Step 1: AI に下調べさせ, 設計書に

prompt から書き始めず, まず AI に **文献調査** させてノート (markdown/LaTeX) にまとめさせる:

- **Onsager 厳密解**: $T_c = 2 / \ln(1 + \sqrt{2}) \approx 2.269$ ($J = k_B = 1$), 厳密磁化曲線・比熱.
- **Binder cumulant**: $U_L = 1 - \langle M^4 \rangle / (3 \langle M^2 \rangle^2)$. 異なる L の曲線が T_c で交差する.

この数式ノートが **inspectable な設計書** の核になる.

Onsager, Phys. Rev. 65, 117 (1944) ・ Binder, Z. Phys. B 43, 119 (1981). テンプレ: 問題 / 定式化 / 仮定 / algorithm / 擬似コード / invariants / reference / error metrics / test plan

Step 2: 何を unit test し, 何を oracle で見るか

MC は乱数を含むので「出力一致」テストは難しい. **何が決定的に検査できるか** を AI と議論して切り分ける:

unit-test できる (決定的)	oracle で見る (統計的)
周期境界の index 計算	$\langle E \rangle, \langle M \rangle$ の期待値
1 スピン反転の ΔE	比熱・帯磁率のピーク
受容確率 $\min(1, e^{-\beta \Delta E})$	Onsager との一致
detailed balance / 可逆性	Binder の交差

- **小さな系 (例: 2 スピン)** は全状態を厳密に数え上げられ, 超長時間もサンプルできる.
→ 統計量でも **失敗確率 ≈ 0 の準決定的テスト** になる.

Step 3: 実装させ、逆変換して照合

- 設計書をプロンプトに Rust 実装させる.
- 実装後, AI に 数式・擬似コード・invariant を逆に出力させ, 設計書と突き合わせる.
- 人間が読むのは コードそのものではなく, この「コード $\leftrightarrow$ アルゴリズム・数式」の対応.
- ただし 最初はコードも目で見て 確認する. わからない部分は AI に質問する.



ここはライブで実演する.

Step 4: $\langle M \rangle$ は有限時間で 0 に戻らない

- まず Onsager 厳密解 (T_c ・磁化曲線・比熱ピーク) と突き合わせる.
 - Z2 対称性 ($s_i \rightarrow -s_i$) は厳密には $\langle M \rangle = 0$ を要求する.
 - だが T_c 以下では single-spin-flip Metropolis は系全体を反転できず, 片方の磁化セクターに捕まる (ergodicity の実効的破れ). 有限時間平均では $\langle M \rangle \neq 0$.
- これはバグではなく, アルゴリズムの限界. 型も compiler も検出しない. 止めるのは oracle.

Step 5: 得た知見を正本に書き残す (Task 1 の仕上げ)

Task 1 で分かったことを **次のセッションへ引き継ぐ** ため, rules に書き足して育てる:

- T_c 以下の秩序変数は $\langle |M| \rangle$ を使う ($\langle M \rangle$ は有限時間で 0 に戻らない).
- MC の unit-test 境界: 決定的部分のみ, 小さな系で準決定的に検証する.

→ **AGENTS.md / REPOSITORY_RULES.md** に書き込む = 正本を育てる 1 サイクル.

もう一周: アルゴリズム拡張

Task 2: 混合 (mixing) を速くする

- 別タスク として, 同じサイクルをもう一周 (また Step 1 から).
- 問題: single-flip は T_c 近傍で 臨界減速, T_c 以下で セクター間を遷移できない.
- 拡張案 (Step 1 で下調べ・設計させる):
 - ▶ レプリカ交換 (parallel tempering): 複数温度を並走させ隣接を交換. 高温側が障壁を越える.
 - ▶ クラスター法 (Wolff / Swendsen-Wang): スピンの塊を一括反転し, 臨界減速を回避.

Replica exchange: Hukushima and Nemoto, J. Phys. Soc. Jpn. 65, 1604 (1996). Cluster algorithms: Swendsen and Wang, Phys. Rev. Lett. 58, 86 (1987) · Wolff, Phys. Rev. Lett. 62, 361 (1989).

レプリカ交換の設計: 温度分点をどう置くか

- 温度集合 $\{T_i\}$ の配置 = 設計判断 (Step 1):
 - ▶ 隣接 replica の 受容率を一定 (20~40%) に → エネルギー分布の重なりを確保.
 - ▶ 実務: 幾何級数 配置から始め, 受容率を見て調整.
- 実装 → $\langle M \rangle$ / Binder の改善 を検証 → 温度配置の知見も 正本に書き残す.

 Task 2 はライブで実演する.

參考資料

本講義の準備にあたり, **有益な議論** をいただいた (敬称略):

Jin-Guo Liu · Lei Wang · Satoshi Terasaki

CompPhysHack2026

本講義の前提となるハッカソン (公式サイト). [寺崎ハンズオン教材](#) も参照

Sustainable Automation

Jin-Guo Liu

[CLAUDE.md](#) (記憶) + [Skills](#) (手順) + サブエージェントで AI 協働をセッション・週・プロジェクトを越えて持続可能にする方法を, C コンパイラの 10 万行天井を例に論じる

superpowers

brainstorm → plan → execute を Skills として強制するワークフロー (本日のハンズオンで使用)

MIT missing-semester

agentic coding 入門 (CLI エージェントの基礎)