

Agentic AI Coding × Rust

Growing computational–physics code you can verify

Hiroshi Shinaoka

Saitama University

事前准备

事前准备 (每人, 课程前完成)

1. 安装一个 CLI 型代理.

- 免费: [Gemini CLI](#) / ChatGPT Plus 及以上: [Codex](#) / 其他工具也可以.
- 安装指南: [Satoshi Terasaki](#) / [Junya Ito](#).

2. 准备一个编程语言工具链.

- 今天使用 [Rust](#) , 但其他语言也可以. 若使用 Rust, [安装 Cargo](#) (参考).

今天的流程


- 前半 = 方法论 / 后半 = 二维 Ising 实操.
- 当天只做 环境检查: 主要时间用于方法论和实操.
- 二维 Ising 是经典问题, 因此即使免费模型也应能跑完整流程 (大概).

导入



自我介绍与今天的立场

- 东京大学 PhD → 瑞士博士后 → 埼玉大学 PI (2015~)
- 从量子多体计算到第一性原理计算的广泛经验
- IR basis / sparse modeling / tensor networks
- **C++ / Python / Julia / Fortran** 的实际开发经验
- 参与 OSS 与社区贡献



现在我一行代码也不手写, 也不逐行阅读生成代码. 即便如此, 我仍然认为 **代理式编码** **比手动编码更可信**. 为什么?

常见批评: “AI slop”

有人把代理式编码的产物称为 “AI 垃圾产物”:

工匠性的丧失

Sinclair Target

“...would prefer not to use agentic tools **even if they worked as advertised.**”

即便工具能工作, 人也会失去对工作的关心. [Quality in the Age of Slop, 2026](#)

维护崩溃

D. Stenberg (curl)

“The current torrent of submissions put a high load on the curl security team...”

curl 被 AI slop 淹没, 关闭了 bug bounty (2026). [The Register](#)

共享资源劣化

Baltes et al.

“...a tragedy of the commons, where individual productivity gains **externalize costs onto reviewers, maintainers, and the broader community.**”

[“An Endless Stream of AI Slop”, arXiv:2603.27249](#)

过度宣传的反作用


Anthropic C compiler

用 16 个并行 Claude 实例构建 C 编译器 (100K 行, \$20k). 独立基准测试显示它 **快于 GCC -O0, 但仍落后于 GCC -O2**. 评价目标不清楚时, 这类展示会 **扩大对 AI 的怀疑**.

[Anthropic · benchmark](#)

优化不足 **并不是 AI 做不到的证据** 它说明缺少性能 oracle, 也说明 human-AI loop 不够紧密.

编码的工业革命: 从手工业到工厂



人类逐件精心制作
= 手动编码


用模具大规模生产 (高速 · 均质)
= 理想的代理式编码

同样的转变正在 代理式编码.

我们正处在思考如何实现 理想的代理式编码.


手动（工匠模式）编码的局限

Scientific computing



Held up by a few artisans
(PD / staff leave → unmaintainable)

Large project



Issues & PRs keep piling up
(manual review can't keep up)

→ 两者都是 依靠人力支撑 模式的局限.

今天的主张 (概要)

我把信任的放置点从 目视检查 转移到 机械化 · 外部验证:

Compiler · test · oracle · rules 取代目视, 支撑正确性.

底层观点: AI 的高速生成是工业化大规模生产. 与其逐个修产品, 不如修 模具 (= 正本: rules · oracle).

编码代理的基础

聊天型代理 vs CLI 型代理

聊天型 (浏览器对话)	CLI 型 (终端)
提问后复制粘贴答案	直接编辑并运行文件
不能访问本地环境	操作 repo 与 git
每一轮都由人搬运	自主执行多步任务

CLI 型代理是 面向长时间自主执行的设计. 这是今天的主角.

按代际来说: Gen1 (Cursor / Copilot) → Gen2 (Claude Code / Codex / ...). [MIT missing-semester: 代理式编码](#)

代表性的 CLI 代理 (执行框架)

Claude Code	Anthropic. 在终端/IDE 中自主编码
Codex CLI	OpenAI. Rust 制 OSS, 随 ChatGPT 计划提供
Gemini CLI	Google. OSS, 有免费额度
Kimi CLI	Moonshot (中国). 模型 K2.7 Code
OpenCode	OSS, 不绑定模型提供方
Pi	极简 OSS. 可自行添加扩展和技能来培养它 (适合极简主义者)

执行框架 ≠ 模型

- 执行框架 = CLI 工具 (编辑文件, 执行命令, 调用工具的框架).
- 模型 = 底层运行的 LLM. 许多执行框架允许 替换模型.
 - 中立: OpenCode / Gemini CLI · 偏自家集成: Claude Code / Codex.
- 性能由 模型 决定, 可用性和自主度由 执行框架 决定. 两者都要选择.

订阅 vs API, 以及低价模型

订阅	Claude Pro \$20/月 (含 Claude Code) / ChatGPT + Codex. 固定月费 + 使用额度
API 按量付费	按使用 token 计费. 可把任意模型接到执行框架

低价编码向 API (2026): DeepSeek V4 Flash (输入 \$0.14 / 输出 \$0.28 每 1M token) · Kimi K2.7 Code. 例如: OpenCode + 低价 API 可以低成本开始.

价格和模型名截至 2026 年 6 月. 世代更新很快.

什么是技能

- **Skill** = 代理的 **操作手册** (markdown). 它把抽象任务拆成明确的小步骤.
- 它接近程序中的函数, 但操作对象是 **代理的行为, 而不是数据**.
- 它会在相关工作中 **自动触发**, 技能也会调用其他技能来组合复杂流程.
- **CLAUDE.md / AGENTS.md** = 跨会话保存的记忆 (规范, 命令, 结构).

实际工作流的样子

superpowers 技能强制 **brainstorm** → **plan** → **execute** (各阶段自动触发):



- 起点不是 prompt, 而是 **带数学依据的设计文档**. 同时设计验证 (oracle / test).
- 实现后让 AI 输出 **code** ↔ **algorithm/math** 的对应关系并核对 (有时完全不读代码本身).
- Execute 阶段是 TDD + 子代理分工; Review 发现问题则回到前一阶段.

过去一年：把代理式编码推到极限

我是如何走到这里的

自 2025 年 10 月以来, **我没有手写过一行代码**. 也不逐行阅读生成代码.

- 2025 年 1 月** 开始使用 Cursor, 仍是看源代码的世代
- 2025 年 10 月** 开始将 `SparselR.jl` 从 Julia 移植到 Rust
- 2025 年 12 月** 切换到 Claude Code: **停止逐行阅读生成代码**
- 2026 年 1 月** 开始 `tensor4all-rs`: Julia TN 生态的 Rust 移植
- 2026 年 2 月** 开始 `tenferro-rs`: Rust 制 PyTorch 式张量栈
- 2026 年 3 月~** 现在主要使用 Codex

做出的东西: tensor4all-rs

将 Julia 的 tensor learning stack 移植到 Rust.

[TensorCrossInterpolation.jl](#) / [QuanticsTCI.jl](#) etc. / [SciPost Phys. 18, 104 \(2025\)](#) / [tensor4all](#)

GitHub: github.com/tensor4all/tensor4all-rs

- 2026 年 1 月 1 日开始 (原本是寒假中测试代理式编码“极限”的自由研究)
- 少数人类 + AI (从 Claude Code 到主要使用 Codex)
- 2 个月 353 commits · 最初 2 周 +61,486 行 (151 个文件)

→ 合作者之间关于 AI slop, 教育法, Julia 是否仍然必要的讨论仍在继续.

“经过大量试错和失败, 正确的代理式编码方法才开始显现.”

设计, 测试与验证, 合适的语言, (教育法)...

有意的实验: 把代理式编码推到极限

“观察失败, 并寻找控制失败的方法.”

原来的 Julia 生态很大, 覆盖 Quantics Tensor Train (QTT) / Tensor Cross Interpolation (TCI). 其中一部分依赖 ITensors.jl.

最初从“单体结构”开始: 移植 ITensors.jl 中需要的部分 (index system, tensor contraction) + QTT/TCI.


失败例

(如预期) 出现了大量问题

- 破坏抽象: 在高层导入并使用低层功能 (临时修补)
- 悄悄放宽单元测试阈值 (放弃修 bug)
- 不用 BLAS, 而是写 nested loops (结果正确, 但是...)
- 单个源文件超过数千行
- ...

复杂度持续增长

- 逐个修补跟不上.
- 为了长期维护, 只能 **培养一套统一的** 思想和设计规则.
- 否则复杂度会持续增长.



修正“规则”，而不是“代码”

参考

- Heinrich pyramid: 一个安全工程经验法则, 即一个重大事故背后有许多轻微事故和 near miss.
- 航空事故调查: ICAO Annex 13 将调查目的定义为预防, 而不是追责.

SKYbrary: Heinrich Pyramid · ICAO Annex 13 · NASA ASRS

我在代理式编码中的对策

- 通过建立“规则”和“制度”来矫正 AI 的行为
- 构建机械化审计和批量修正代码的机制

(这种机制在手动编码时代也一直很重要.)

→ 兼顾 AI 压倒性的高速代码生成与质量控制

单体 → 分离结构 (用结构强制约束)

把巨大的 tensor4all-rs 拆成职责不同的独立层.

Tensor4all.jl

github.com/tensor4all/Tensor4all.jl

面向人类的接口 (Julia, 兼容 ITensors)

tensor4all-rs

github.com/tensor4all/tensor4all-rs

张量网络: TreeTN / QTT / TCI

tenferro-rs

github.com/tensor4all/tenferro-rs

通用张量计算 + 自动微分 + GPU (类似 PyTorch/JAX)

tidu-rs

github.com/tensor4all/tidu-rs

通用自动微分引擎


一旦分层完成, AI 只能在各层内部活动, 不能破坏层次结构.

单体 → 分离结构 (用结构强制约束)

层和 API 边界由 AI 一起分析 PyTorch / JAX 后设计. (Jin-Guo Liu: tenferro 初期设计, Satoshi Terasaki: 开发支持, tensor4all collaboration: tensor4all-rs / Tensor4all.jl 开发)

各层内部的模块化

tenferro 内部也被模块化.



No root facade. Each family is a first-class crate.

在 Rust 中可以沿模块层次细粒度控制符号可见性. AI 编码代理不能从外部擅自 import 私有符号.

可验证性优先于可读性

以下讨论以“大型代码库”的开发为前提.

语言选择的理由发生反转: 我自己的说法变化

2023 年 3 月 (那霸, 计算物理春季学校 2023 前夜祭)

最近我常用 Jupyter Notebook 做原型. Julia 的代码看起来接近数学, 易于检查, 内存管理也处理得很好, 因此很舒服. 我也对 Rust 感兴趣, 但对一般学生来说学习门槛高, 数值计算库也还不够成熟.

2026

现在我不再用 Jupyter Notebook 做原型. Rust 的内存管理严格而显式, 对代理式编码更高效. 代码由代理来写, 因此陡峭的学习曲线不是问题. 在 AI 帮助下, 即使代码稍长, 保持代码与数学一致也不是问题. 缺失的数值库可以移植到 Rust.

可验证性优先于可读性

手动编码时代: 各语言带来的“好处”

Fortran	数组是语言原生能力 · 手写循环也快 · LAPACK / BLAS 触手可及
Python	交互式试验 (REPL / notebook) · numpy / scipy / matplotlib · 立即可视化
Julia	记法接近数学 (broadcast / Unicode) · JIT 带来速度 · 原型接近生产代码

共同点: 它们都降低了 人类手写, 阅读, 维护 代码的成本.

选择语言的指标变化: 大规模开发

过去重要的指标都默认 人类写代码并维护代码:

传统指标	代理式时代
可读性: 逐行跟踪	可验证性: 用 oracle 检查
平缓的学习曲线	陡峭部分由 AI 接管
接近数学: 目视验证	与机械化检查结合
书写速度	不再是瓶颈

容易检查 优先于 容易阅读.

可读源码 $\neq$ 可检查实现

可读 和 可检查 是不同的事情.

例: 即使 Julia 的 broadcast 赋值 看起来 接近数学, 也无法仅凭外观确定行为:

```
b = a           # b and a point to the same array (alias)
a .+= c         # if updated in-place, b changes too  $\leftarrow$  side effect
```

aliasing / mutation / allocation 无法从一行代码的外观中看出.

到这里为止与语言无关. 那么哪种语言适合可验证性?

Rust 是什么 (面向本听众的最低限度)

- 来自 **Mozilla** 的系统语言. 为 Firefox 实现而开发, 2015 年发布稳定版 (1.0).
- 因可靠性受到重视, 已被 **Linux kernel** 正式采用 (v6.1 以后, C 之后的第二种语言).
- **所有权**: 没有 GC 的内存安全. 数据竞争和悬垂指针在 **编译时** 被排除.
- **Cargo**: build, 依赖解析, testing, benchmarking 被标准化整合.

给物理学家的一句话: “**安全的 C++ + 一流的 build/dependency manager**”.


速度是 C / C++ 级, 安全性是 GC 语言级.

生态系统的加速增长


crates.io crate count by year

Source: crates.io DB dump, 2026-06-02T02:00:24.375042Z. Includes deleted crates when reconstructing Jan 1 active counts.
2026 is partial through the dump timestamp.

Active crates at Jan 1



New crates created in each year



Counting rule: crates.created_at plus deleted_crates.created_at; active_at_jan1 subtracts crates deleted before that date.

2026 年 NVIDIA 也发布了 Rust 的 CUDA 内核编译器 [cuda-oxide](#) (实验阶段).

Why Rust? 与 AI 的快速反馈循环

Python / Julia 是为了 **快速书写** 而设计的. 在 AI 时代, 这个优势会 **反转**:

Python / Julia	Rust + AI
手写速度快	AI 来写: 速度相同
错误在运行时暴露	编译时捕捉
验证需要执行	cargo check 数秒完成
AI 的错误发现较慢	AI 的错误被 立即 发现

*这里假设大型代码库.

Zenn: Why I Migrated from C++ to Rust


个人经验

- `tenferro-rs` + 外部依赖从零构建约 2 分钟 (Macbook Pro)
edit→test 数十秒完成, cargo check 几乎瞬时.
- AI 处理所有权 / 生命周期的 **机械复杂性**
→ 人类可以集中验证 **算法, 设计, 正确性**.
- Cargo 解析 pure-Rust 依赖. 不需要 CMake.
链接时没有版本冲突.

个人而言, 我在 Julia/C++/Python 中感到的“代码变大后验证变难”的不安消失了.

[tensor4all-meta/docs/why_rusty_julia.md](https://github.com/tensor4all-meta/docs/blob/main/why_rusty_julia.md)

学习曲线: AI 接管陡峭的初期部分



只剩下 Rust 最好吃的部分.

我组里的学生也在从 Julia 迁移到 Rust.

代理式编码时代的工作流: 语言可以混用

- 以前: 在 Jupyter Notebook 中交互式尝试.
- 现在: 用自然语言指示 AI
生成代码 → 计算 → 保存结果到文件 → 绘图
- 为了原型开发, Jupyter Notebook 不是必需品.
- 不需要把所有计算放在单一语言里. 可以利用既有资产, 同时 逐步迁移到 Rust.

选择基准从 最小化认知成本 转向 最大化可验证性.

用三根支柱支撐

用三根支柱支撑巨大且高功能的代码库

tenferro-rs 约 13 万行, 是处理 einsum · FFT · 自动微分 (AD) · GPU 的高功能栈.
逐行 review 不可能, AI 的设计选择也会每次摇摆. 不是让人类站岗, 而是用三根支柱支撑.

tenferro-rs (130K lines)

einsum · FFT · 自动微分 (AD) · GPU ...

支柱 1

单元测试 / 集成测试

并行编译 + 并行测试
快速反馈

支柱 2

Oracle / 基准测试

正确性/性能的外部基准
AI 无法擅自修改

支柱 3

正本 (Rules / Docs)

AI 与人类共同遵守
source of truth

支柱 1: 单元测试 / 集成测试

把输入输出与期望值对照的自动测试群. 按粒度分为两个层级:

Unit test 细粒度验证单个函数或模块 (Rust 中为同文件内的 `#[test]`)

Integration test 验证多个模块/crate 组合后的行为 (Rust 中在 `tests/` 下)

- 每次代码改变都运行全测试, 立即发现哪里坏了.
- **Rust 起作用的地方**: 依赖 crate **并行编译**, 测试也 **默认并行运行**. 整个测试套件数十秒跑完.
- → 即使 AI 重写实现, 也能立即得到绿/红反馈, 形成快速反馈循环.


支柱 2: Oracle 与基准测试 (外部基准)

- **oracle** = 正确性的外部基准: 解析解, reference 实现, 不变量.
- **benchmark** = 性能的外部基准: 可复现地测量.
- 放在独立的 (外部) **repository** → AI 无法擅自修改.


例: **tenferro-benchmark** (性能) / **tensor-ad-oracles** (AD 的数值正确性).

支柱 3: 为什么需要正本

- **正本** = rules, design, worklog 的总体. AI 与人类共同遵守.
- 如果它不成长, 就会得到 **AI slop**: 失败停留在一次性修补, 同类问题在其他地方复发.
- **打地鼠式个别修补跟不上, 复杂度持续增长.**
- 三根支柱中最被低估的一根 → 接下来说明如何培养它.



AI 记忆不是正本




项目判断应写入 repo 内的正本, 而不是留在 AI 聊天历史或 memory 功能中. 漫画: [Jin-Guo Liu: Sustainable Automation](#)

从失败中培养正本

自 2025 年 10 月以来, 我停止逐件介入, 转向把判断积累为 **正本**. **从失败中一般化并让它成长**.

实现 → 失败 → 一般化 → rule/oracle → 下一次约束.



tenferro-rs / REPOSITORY_RULES.md (摘录)

- ... are first-class crates, not a broad “tenferro” facade.
- No naive CPU loop fallbacks. Use strided-kernel / faer / BLAS.

这些是我经历的 **从失败中诞生的规则** (内置→分离, naive loops 的痛点).

积累并维护正本

AGENTS.md	AI 与人类共同遵守的工作规范
REPOSITORY_RULES.md	禁止事项 · source of truth · 性能契约
docs/design/, worklogs/	要维护的设计思想 · 为什么做出该判断
oracle / benchmark	正确性 · 性能的外部基准

- 让 **代理自身持续** 检查正本↔代码的一致性 (drift = correctness concern).
 - 把信任对象从“AI 的说明”转移到 **rule / oracle / CI / provenance**.
- 接下来从 **外部验证** 已培养的正本是否真的有效.

从外部验证: 让第三方 AI 审计

Ask AI: 阅读下面 3 个 repo, 调查大型代码库中用于一致性和质量控制的工夫.

- <https://github.com/tensor4all/tenferro-rs>
- <https://github.com/tensor4all/tenferro-benchmark>
- <https://github.com/tensor4all/tensor-ad-oracles>

在我的试行中, ChatGPT Pro 仅通过阅读 repo 就重构出了质量控制结构:

- **性能** = tenferro-benchmark / **AD 的正确性** = tensor-ad-oracles → 它抽取出了 **支柱 2 (外部基准)**.
- **结构一致性** = CI + repository rules + first-class crate 拆分 → 它抽取出了 **支柱 3 (正本)**.

如果正本齐备, 即使第三方 AI 也能读出设计意图.

复现用 prompt 是上面的 code block. 目标 repo 是可从外部读取的 public GitHub repo.

把审计自动化: 检测靠 Bot, 修复靠人类

正本 + 代码



审计 Bot 在 private CI 中持续运行 (人类也可运行同一工具)



把不一致 · bug 自动创建为 Issue



人类 用 GPT-5.5 批量修复

不把修复完全交给自动化, 是 责任与选择的问题, 而非可靠性: 许多 bug 背后可能藏着设计缺陷.

教育



合作者的担忧

新的 workflow 也有反对意见 (来自 tensor4all 合作者):

① library $\neq$ application	Application 没有 reference answer
② 注意学习阶段	让 junior 原样采用 senior 的 workflow 还太早
③ Julia 的可读性	小 notebook 使 目视检查与数学的一致性 更容易

我的个人回答

①	即使 application 也有可检查对象: 对称性, 极限情况, 守恒律. 找到它们才是关键.
②	按学习阶段区分: 基础阶段手写学习, 研究阶段学习 agentic engineering. 不要一刀切地要求.
③	目视检查并不总是可信. 如果也 让 AI 生成伪代码并核对, Rust / C++ 也会变清楚.

“工业革命”已经发生. 我们需要从实践构建教育管线. 没必要固守过去的风格.

总结

总结

1. **工作流**: brainstorm → plan → execute. 从 **带数学依据的设计文档** 开始, 而不是从 prompt 开始, 并先设计验证.
2. **三根支柱支撑**: 单元/集成测试 · oracle/基准测试 · 正本 (rules) 维护巨大代码库.
3. **教育**: 基础阶段手写, 研究阶段学习 agentic engineering. 按学习阶段区分.

→ 人类的工作主要变成 **提出项目, 设计项目, 验证项目**.

实操: 二维 Ising, 验证驱动

设置: 最先告诉 AI 的事

- **git** 是必需的: 它是历史, 差分, review, CI 的前提. 从 `git init + .gitignore` 开始.
- 今天的语言是 **Rust**. Python / Julia 也可以 (只要能构建 oracle, 语言不是本质).
- 如果使用 Rust, 让它创建 **标准目录结构 + 测试层级**:
 - `src/` 内 `#[cfg(test)]` 放 **单元测试** · `tests/` 放 **集成测试**.
- 并且一开始就准备: `AGENTS.md` / `CLAUDE.md` (规范, 命令, 结构) · `README` · `cargo fmt + clippy` · **seeded RNG (可复现性)** · 结果保存到文件, 绘图分离.

今天的循环和两个任务

把前半的 **superpowers workflow** 应用于二维 Ising. 每个任务运行 **一轮循环**:

Step 1 让 AI 做背景调查, 并写成带数学依据的设计文档 (markdown/LaTeX)

Step 2 讨论要做哪些单元测试, 决定 oracle 和验证计划

Step 3 实现 → 让它输出数学 / 伪代码 / 不变量并核对

Step 4 用 oracle 验证 (与 Onsager 比较, 检查 $\langle M \rangle$ 的有限时间行为)

Step 5 把学到的经验写入正本 (rules)

- **Task 1**: 基本二维 Ising (Metropolis).
- **Task 2**: 算法扩展 (副本交换) = 另一个任务. **再次从 Step 1 开始** 并再跑同样的一轮循环.

题材和规格: 二维 Ising

- 统计力学经典问题: 有精确解 (Onsager), 因此 **oracle 齐备**. 问题足够知名, 即使免费模型也能实现.
- $H = -J \sum_{\langle ij \rangle} s_i s_j$ (周期边界), Metropolis 更新. 观测量 = 能量 / 磁化强度 / 比热 / 磁化率.

基于既有教材的 Ising 章 [rust-computational-physics-tutorial](#). 精确解: Onsager (1944).

Step 1: 让 AI 调查并写设计文档

不要从 prompt 开始写; 先让 AI 做 **文献调查** 并整理成笔记 (markdown/LaTeX):

- **Onsager 精确解**: $T_c = 2 / \ln(1 + \sqrt{2}) \approx 2.269$ ($J = k_B = 1$), 精确磁化曲线和比热.
- **Binder 累积量**: $U_L = 1 - \langle M^4 \rangle / (3 \langle M^2 \rangle^2)$. 不同 L 的曲线在 T_c 处交叉.

这份数学笔记成为 **可检查设计文档** 的核心.

Onsager, Phys. Rev. 65, 117 (1944) · Binder, Z. Phys. B 43, 119 (1981). 模板: problem / formulation / assumptions / algorithm / pseudocode / invariants / reference / error metrics / test plan

Step 2: 什么做单元测试, 什么用 oracle 检查

MC 含有随机性, 因此“输出完全一致”测试很难. 与 AI 讨论并切分出 可以确定性检查的对象:

可单元测试 (确定性)	用 oracle 检查 (统计性)
周期边界 index 计算	期望值 $\langle E \rangle, \langle M \rangle$
单自旋翻转的 ΔE	比热 / 磁化率的峰
接受概率 $\min(1, e^{-\beta \Delta E})$	与 Onsager 一致
细致平衡 / 可逆性	Binder 交叉

- 对于 小体系 (例如 2 个自旋) 可以精确枚举所有状态, 并进行任意长时间采样.
→ 即使统计量也变成 失败概率为 ≈ 0 .

Step 3: 让它实现, 再反读并核对

- 以设计文档为 prompt, 用 Rust 实现.
- 实现后, 让 AI 输出 **数学 / 伪代码 / 不变量** 并与设计文档核对.
- 人类阅读的不是 **代码本身**, 而是这种 “code $\leftrightarrow$ algorithm/math” 对应关系.
- 不过, **一开始也要目视代码** 检查. 不理解的部分 询问 AI.

 这里现场演示.

Step 4: $\langle M \rangle$ 在有限时间内不会回到 0

- 首先与 Onsager 精确解 (T_c , 磁化曲线, 比热峰) 对照.
 - Z2 对称性 ($s_i \rightarrow -s_i$) 严格要求 $\langle M \rangle = 0$.
 - 但在 T_c 以下, 单自旋翻转 Metropolis 无法翻转整个体系, 因而 被困在一个磁化扇区 (遍历性的有效破缺). 在有限时间平均中, $\langle M \rangle \neq 0$.
- 这不是 bug, 而是算法的限制. 类型和编译器都检测不到. 能抓住它的是 oracle.

Step 5: 把经验写入正本 (Task 1 收尾)

为了把 Task 1 的经验 交给下一次会话, 将其加入 rules 并继续培养:

- 在 T_c 以下, 使用 $\langle |M| \rangle$ 作为序参量 ($\langle M \rangle$ 在有限时间内不会回到 0).
- MC 单元测试的边界: 只测试确定性部分; 在小体系上做准确定性验证.

→ 写入 AGENTS.md / REPOSITORY_RULES.md = 就是培养正本的一轮循环.

再来一轮：扩展算法

Task 2: 加速混合

- 作为 独立任务, 再运行同样一轮循环 (再次从 Step 1 开始).
- 问题: single-flip 在 临界慢化 附近出现, 并且 无法在扇区之间跃迁 于 T_c 以下.
- 扩展方案 (在 Step 1 让它调查并设计):
 - 副本交换 (parallel tempering): 并行运行多个温度并交换相邻副本. 高温侧跨越能垒.
 - 簇算法 (Wolff / Swendsen-Wang): 一次翻转一簇自旋, 避免临界慢化.

副本交换: Hukushima and Nemoto, J. Phys. Soc. Jpn. 65, 1604 (1996). 簇算法: Swendsen and Wang, Phys. Rev. Lett. 58, 86 (1987) · Wolff, Phys. Rev. Lett. 62, 361 (1989).

设计副本交换: 温度点如何放置

- 温度集合 $\{T_i\}$ 是设计判断 (Step 1):
 - 保持 相邻 replica 的接受率大致恒定 (20~40%) → 确保能量分布重叠.
 - 实践中: 从几何间隔开始 并根据接受率调整.
- 实现 → 验证 $\langle M \rangle$ / Binder 的改善 → 把温度配置的经验 写入正本 中.

 Task 2 现场演示.

参考资料

致谢

本讲义准备过程中, 感谢以下人士的 有益讨论:

Jin-Guo Liu · Lei Wang · Satoshi Terasaki

CompPhysHack2026

本讲义所依托的 hackathon (官方网站). 也参见 [Terasaki 实操教材](#)

Sustainable Automation

Jin-Guo Liu

讨论如何用 [CLAUDE.md](#) (记忆) + [Skills](#) (步骤) + 子代理, 使 AI 协作跨会话, 跨周, 跨项目可持续, 并以 C 编译器的 10 万行上限为例

superpowers

把 brainstorm → plan → execute 作为 Skills 强制执行的工作流 (今天实操中使用)

MIT missing-semester

代理式编码入门 (CLI 代理基础)